第一周项目工作汇报

抖音商城用户行为数据分析 · 第一阶段

汇报周期：2026-11-06 至 2026-11-13 | 提交：2026-11-13

本周重点完成工程环境搭建、数据处理与质量核查；11/13 补齐文献调研和清洗口径确认单。

一、本周已完成

核对项目要求和编码规范；完成全量 CSV 校验、小时四元组全局去重、Parquet 与用户/商品汇总、SQLite 维表和索引、八类图表、解释文档及周计划。

质量指标	实际结果
原始记录	12,256,906
清洗后记录	6,213,379
四元组合并记录	6,043,527（49.31%）
无效记录 / 多类目商品	0 / 0
用户 / 商品 / 类目	10,000 / 2,876,947 / 8,916
数据观察期	2025-11-18 至 2025-12-18

二、关键发现

清洗后购买事件 106,678 条，占全部事件 1.72%；12 月 12 日事件量最高，为 346,464 条；聚合事件峰值在 22 时。

浏览过的用户商品对共 4,677,501 对，严格后续小时购买 54,305 对（1.16%）。另有 41,221 对首次浏览与最后购买同小时，无法确认顺序。

首要待确认问题：是否采用小时四元组去重？该规则合并了 49.31% 的记录。其中可能含真实重复交互，不能全部称为脏数据；请同时确认行为码映射、时区及采样完整性。

方法、验证与下一周安排

三、实施方案与验证

采用磁盘支持的 DuckDB 处理全量数据，查询内存上限设为 2GB，不将本次 1226 万行验证表述为亿级压测。ID 保留字符串，时间按小时解析。

SQLite 共导入 6,213,379 行，外键校验无异常；独立原始计数、行数守恒、Parquet 行数及 SQLite 行为汇总均已交叉核验。

代码采用 4 空格、88 字符行宽、类型注解和 Google 文档字符串。测试覆盖去重、非法输入、前导零 ID、标签边界和右截尾；实际检查日志随仓库提交。

四、文献调研与方法总结

实际只有 1 万用户，与说明中的平台整体规模不同；来源及采样方式待带教确认。缺少金额、订单、曝光及内容侧字段，因此不计算虚假 GMV、RFM 金额或跨场景归因。

已整理 Wide & Deep、DIN、BST 三篇文献的方法、实验与适用限制，形成比较笔记。方法总结：先确定样本与指标口径，再比较模型；论文效果不能直接迁移为本项目收益。

五、下一周安排：11/16 - 11/20

周一：跟进清洗口径与行为码确认，根据反馈固定数据版本及指标定义。

周二：完善用户、商品与交互统计特征，记录计算窗口及字段说明。

周三：检查候选覆盖、时间窗口和标签边界，完善特征防泄漏验证。

周四：复核已完成的初步 LR 基线；视口径确认进度开展树模型对照。

周五：汇总实际实验与问题，提交第二周报告；按带教反馈调整后续安排。

六、未完成项与附件

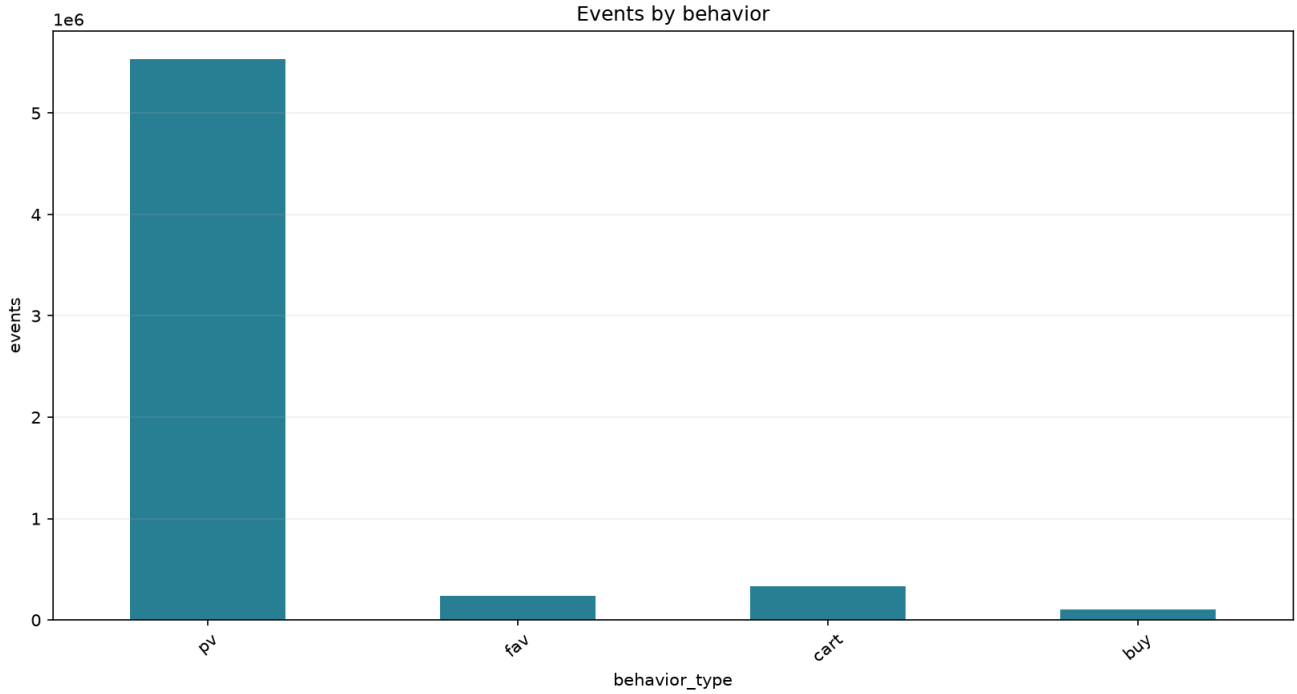
论文实验复现、完整预测特征、树/深度模型、融合解释性和最终 PPT 尚未完成。已提前运行初步 LR，仅作诊断性探索，候选覆盖与预测效果仍需改进。

仓库：https://github.com/sshwdh/douyin-user-behavior-analysis

仓库含文献调研、质量报告、清洗口径确认单及代码。仓库已公开，可通过上述链接直接查看。

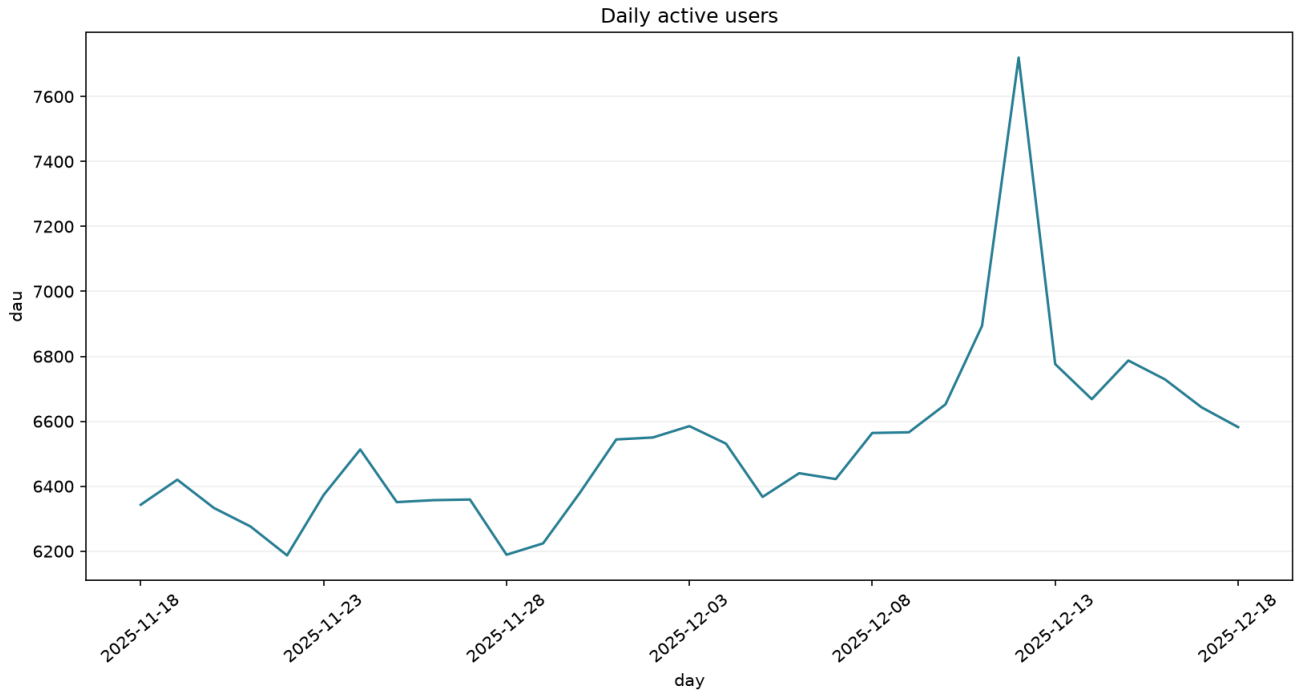
行为结构与活跃趋势

图 1：各类行为事件数



pv=浏览，fav=收藏，cart=加购，buy=购买。采用小时去重事件数；四类行为不构成严格四步漏斗。

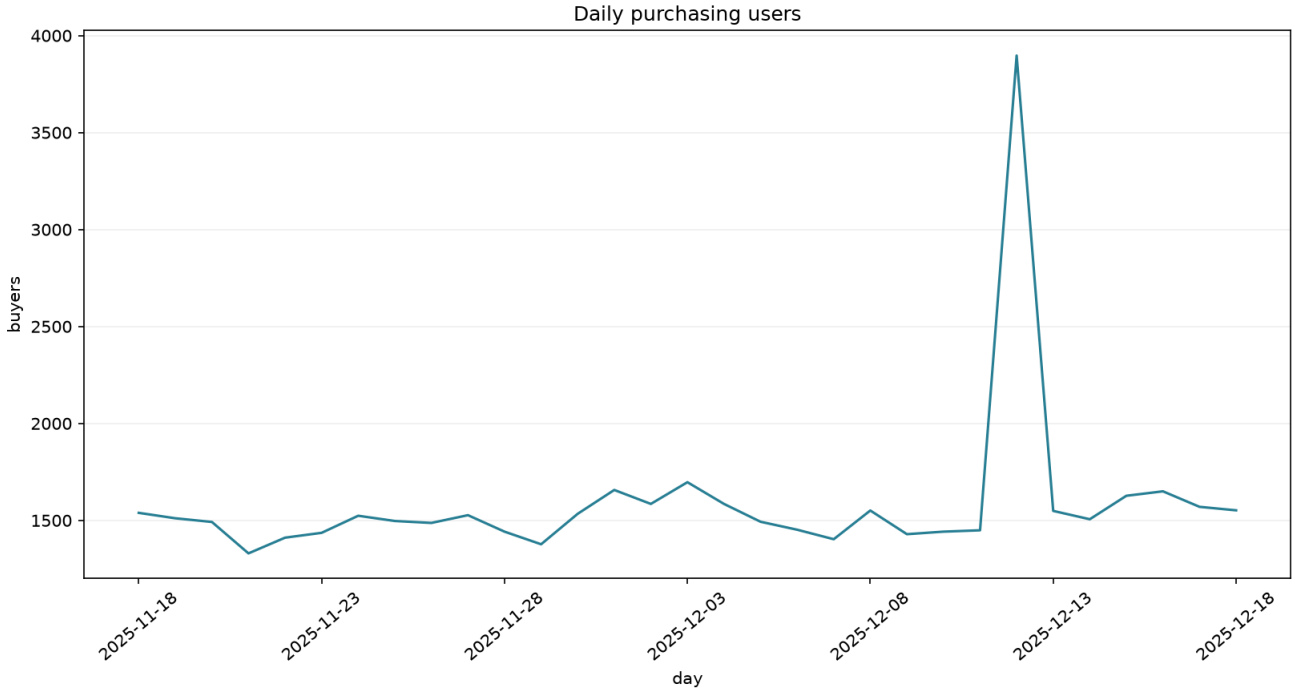
图 2：每日活跃用户



同一天发生任意行为的用户去重计数；12 月 12 日出现峰值，原因仍需业务信息验证。

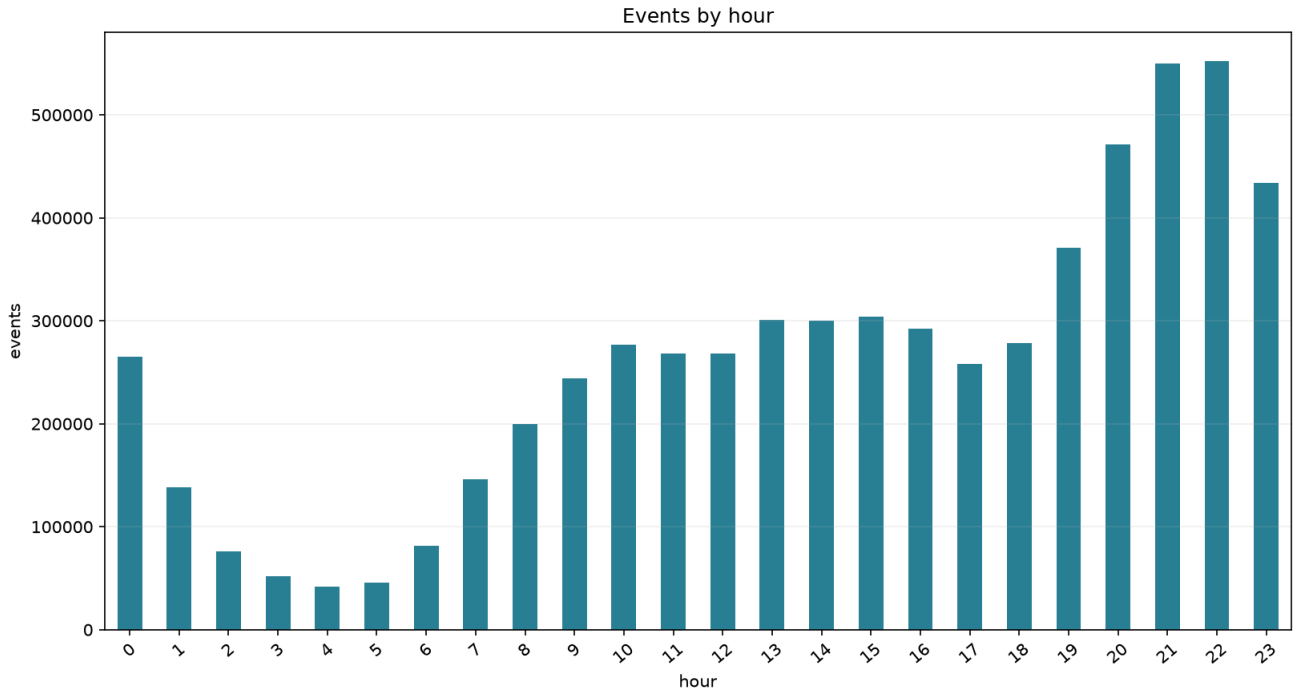
购买趋势与小时分布

图 3：每日购买用户



按日统计行为码为 4 的去重用户；购买用户数不等于订单数，行为映射待带教确认。

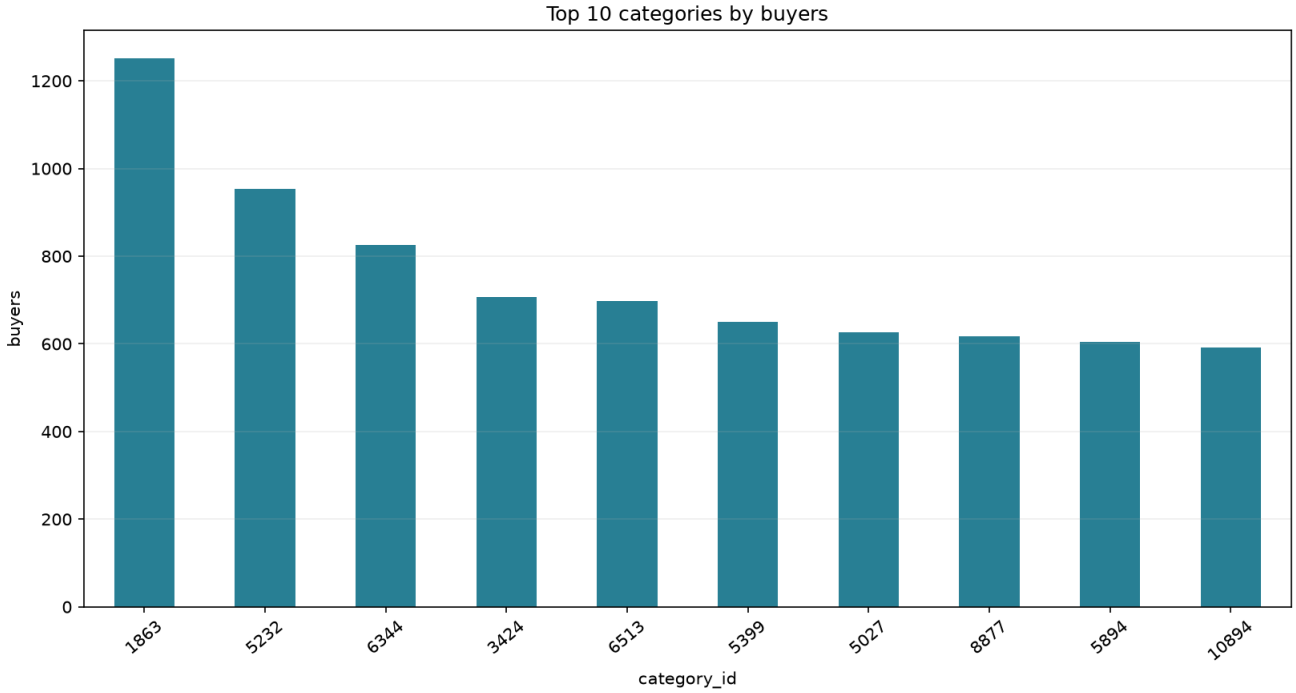
图 4：一天内各小时的事件分布



将观察期全部日期按小时汇总，22 时事件最多；使用原始时间值，业务时区待确认。

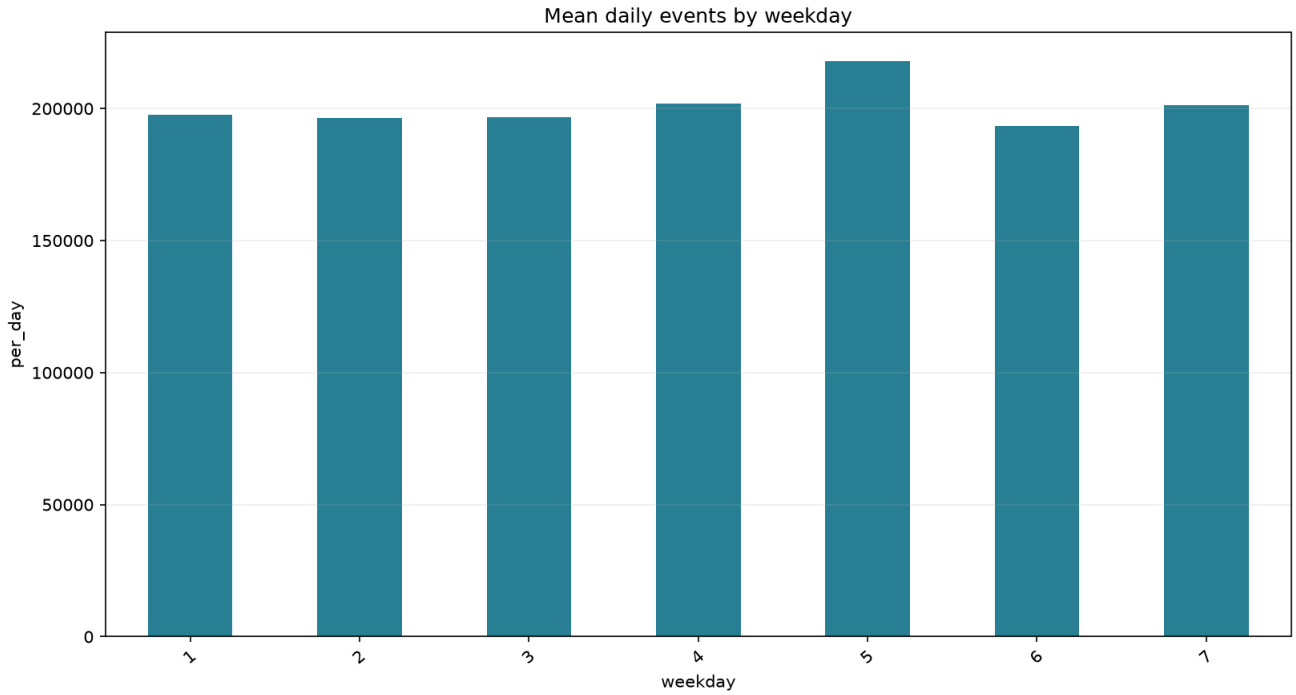
类目偏好与星期分布

图 5：购买用户数前十类目



按类目内去重购买用户数排序；用户可跨类目出现，不能把柱高相加当作总购买人数。

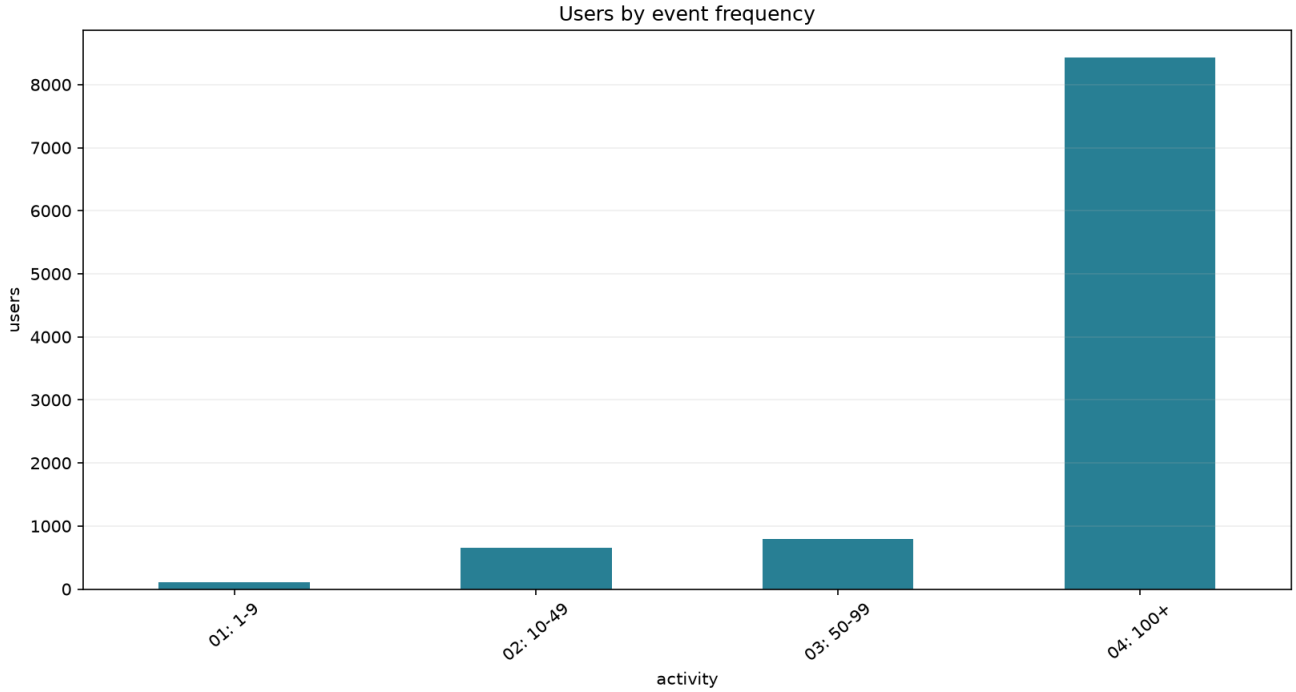
图 6：不同星期的日均事件数



1=周一，7=周日；各星期事件总数除以实际天数。仅一个月样本，不足以证明稳定周期规律。

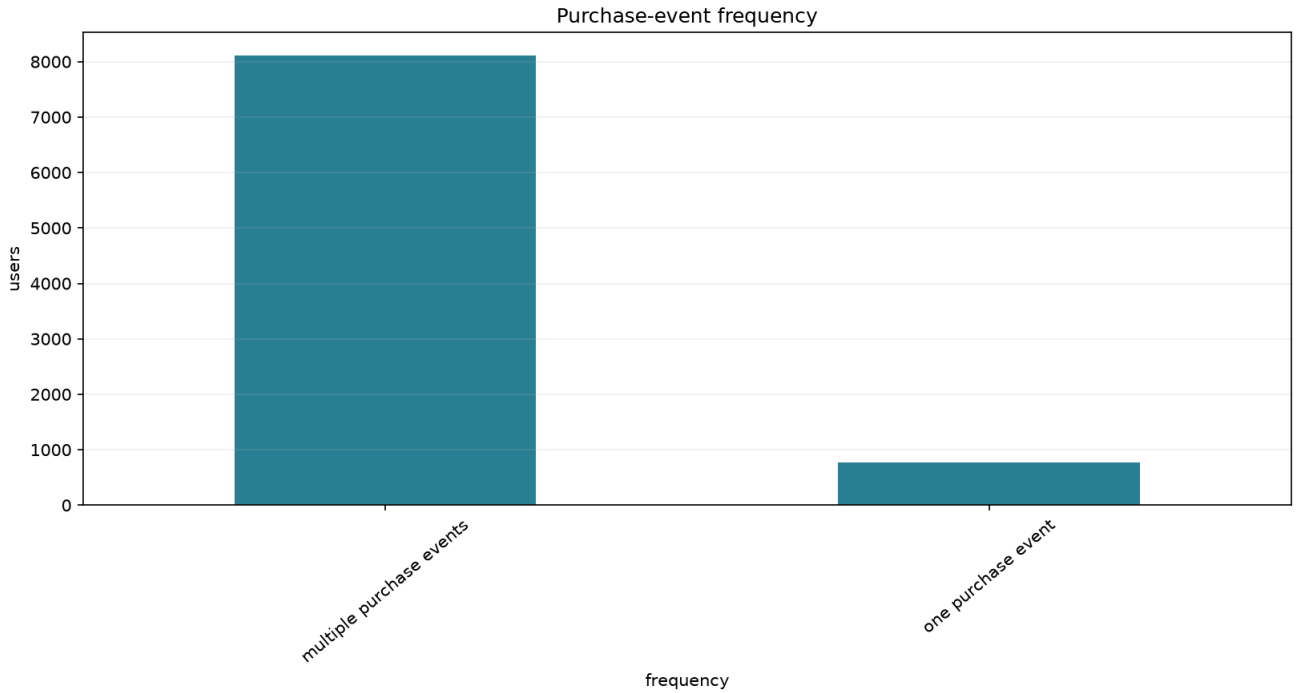
用户活跃度与购买频次

图 7：用户事件频次分布



按整个观察期的小时去重事件数分组：1-9、10-49、50-99、100 及以上；分组受去重规则影响。

图 8：购买用户的事件次数分布



比较一次与多次购买事件的用户数，仅统计购买用户；缺少订单号，不能解释为真实订单复购率。