第一周项目工作汇报

抖音商城用户行为数据分析 · 提交前核对稿

实习开始：2026-11-06 | 计划提交：2026-11-13

本稿记录 11/12 集中推进的实际成果，不倒填此前每日工作。汇报人姓名及个人收获待本人确认。

一、本周已完成

核对项目要求和编码规范；完成全量 CSV 校验、小时四元组全局去重、Parquet 与用户/商品汇总、SQLite 维表和索引、八类图表、解释文档及周计划。

质量指标	实际结果
原始记录	12,256,906
清洗后记录	6,213,379
四元组重复记录	6,043,527（49.31%）
无效记录 / 多类目商品	0 / 0
用户 / 商品 / 类目	10,000 / 2,876,947 / 8,916
数据观察期	2025-11-18 至 2025-12-18

二、关键发现

清洗后购买事件 106,678 条，占全部事件 1.72%；12 月 12 日事件量最高，为 346,464 条；聚合事件峰值在 22 时。

浏览过的用户商品对共 4,677,501 对，严格后续小时购买 54,305 对（1.16%）。另有 41,221 对首次浏览与最后购买同小时，无法确认顺序。

首要待确认问题：49.31% 的记录被小时去重规则折叠。这可能含真实重复浏览，不能全部称为脏数据；已保存逐行为去重敏感性对照。

方法、验证与下一周安排

三、实施方案与验证

采用磁盘支持的 DuckDB 处理全量数据，查询内存上限设为 2GB，不将本次 1226 万行验证表述为亿级压测。ID 保留字符串，时间按小时解析。

SQLite 共导入 6,213,379 行，外键校验无异常；独立原始计数、行数守恒、Parquet 行数及 SQLite 行为汇总均已交叉核验。

代码采用 4 空格、88 字符行宽、类型注解和 Google 文档字符串。测试覆盖去重、非法输入、前导零 ID、标签边界和右截尾；实际检查日志随仓库提交。

四、难点与能力收获

实际只有 1 万用户，与说明中的平台整体规模不同；来源及采样方式待带教确认。缺少金额、订单、曝光及内容侧字段，因此不计算虚假 GMV、RFM 金额或跨场景归因。

个人收获待本人补充：请结合亲自运行的例子，解释事件与用户指标的区别、全局去重的必要性，以及为什么未来标签不能参与特征计算。

五、下一周安排：11/16 - 11/20

周一：补全文献精读，构建用户、商品、交叉窗口特征，核验候选覆盖。

周二：RF、偏好与序列特征，完善小时并列行为及边界测试。

周三：稀疏 SVD、共现与特征筛选，严格限制拟合数据范围。

周四：固定七日标签，完成时间外推 LR 与 7:2:1 分层对照。

周五：树模型、不平衡处理初步对照，提交第二周汇报与实验表。

六、未完成项与附件

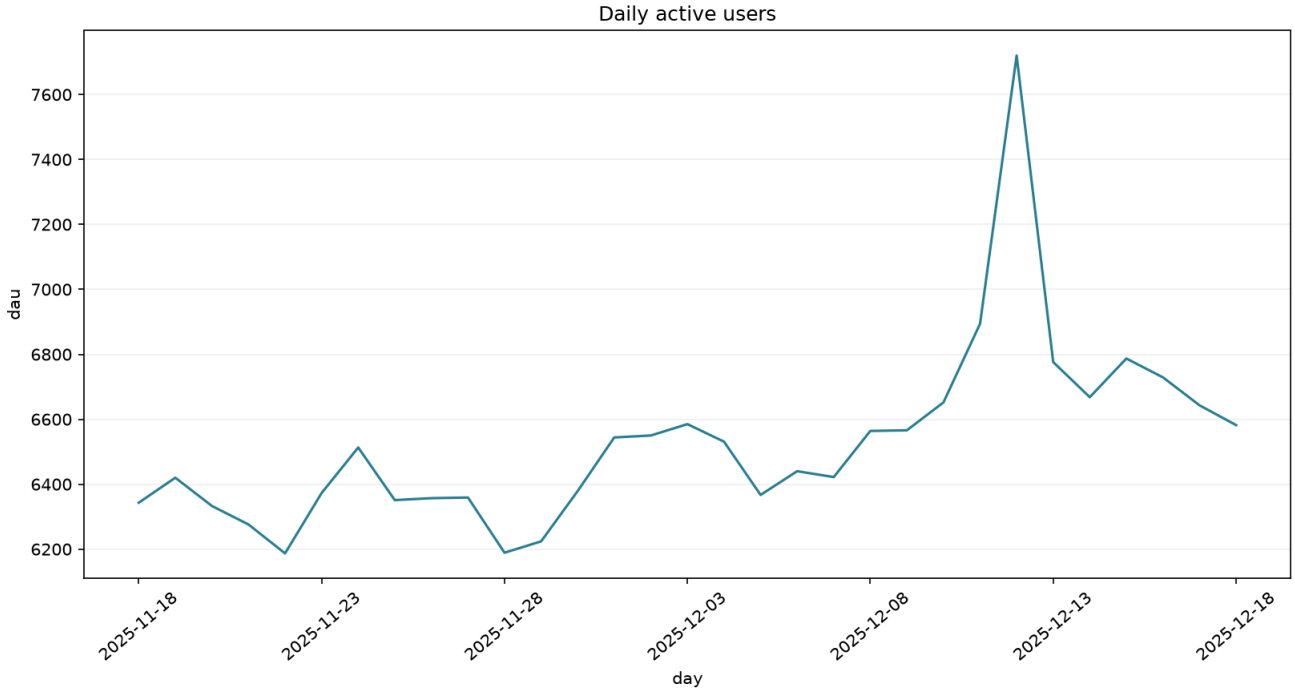
论文实验复现、完整预测特征、树/深度模型、融合解释性和最终 PPT 尚未完成。不以已编写脚本代替训练证据。GitHub 发布以远端文件为准；助教接收渠道待提供。

仓库：https://github.com/sshwdh/douyin-user-behavior-analysis

附件：analysis_report.md、quality.json、结果图片、代码测试及四周执行计划。

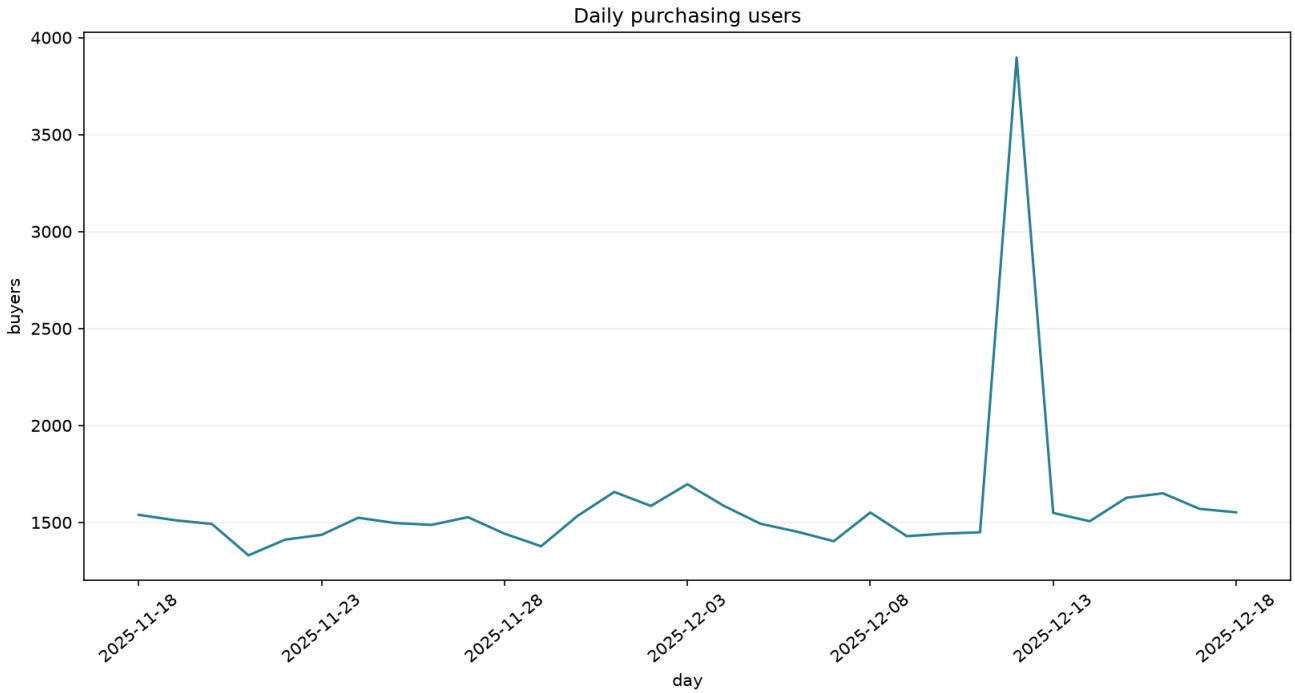
关键结果图

图 1：每日活跃用户（全部行为用户按日去重）



12 月 12 日出现活跃峰值；是否由活动驱动仍需结合业务信息验证。

图 2：每日购买用户（行为码为 4 的去重用户）



购买用户不等于订单数；完整八类图表及汇总 CSV 见附件目录。